

PyTorch 基本练习实验报告

冯傲邦 23307100006

摘要

本研究主要分为三部分。在 Task-1 中，基于线性代数运算从零构建了 Softmax 回归分类器及其前向反向传播闭环，验证了 Ngram 相比 BoW 的特征表示优势，在情感分类数据集取得 48.27% 的正确率与 42.00% 的 F1-Macro。Task-2 利用更现代的卷积神经网络、循环神经网络和 Transformer 针对 Task-1 中同一情感分类数据集进行建模，并进一步采用预训练词嵌入 (GloVe300d)，重点研究了不同卷积架构的性能差异，在控制总参数量级一致条件下对比不同模型架构，Transformer 在三类模型中胜出，取得了 48.87% 的测试集准确率和 42.30% 的 F1-Macro。Task-3 摒弃 `torch.nn.Transformer` 的高级封装，从底层算子出发实现了标准的 Transformer 及其变体架构 Decoder，在逻辑推理（多位数加法）任务中揭示了标准 Transformer 的泛化局限性，对比了两架构的性能差异；同时依托《老友记》剧本语料，完整实践了语言模型 (LM) 的预训练与文本生成链路。

1 Task-1: 基于机器学习的文本分类

1.1 研究背景

文本情感分析是自然语言处理领域的经典任务，其核心挑战在于模型需要精准捕获并解析自然语言中的否定句式、反讽语气、简略表达以及多义词歧义等复杂语义现象。本次研究的 Task-1（基于机器学习）与 Task-2（基于深度学习）均聚焦于该任务，并采用斯坦福大学 Socher 等人标注的，经过样本类别平衡处理的 Rotten Tomatoes 电影评论语料库作为数据集。该语料库要求模型对提取的文本短语进行细粒度的五分类情感预测（消极、较消极、中性、较积极、积极）。

1.2 核心算法与底层张量化实现

本任务独立于 PyTorch 的 `nn` 模块与 `autograd` 自动求导机制，基于基础线性代数运算从零构建了 Softmax 回归分类器，并完成了完整的前向和反向传播闭环。

模型架构：设输入批次特征矩阵 $X \in \mathbb{R}^{B \times V}$ (其中 B 为 Batch Size, V 为词袋或 N-gram 特征维度), 权重矩阵为 $W \in \mathbb{R}^{V \times C}$ ($C = 5$ 为情感标签类别数), 偏置项为 $b \in \mathbb{R}^C$, 真实标签为 $Y \in \mathbb{R}^{B \times C}$, 预测标签为 $\hat{Y} \in \mathbb{R}^{B \times C}$ 。模型采用单层 Softmax 回归:

$$\hat{Y} = \text{Softmax}(XW + b)$$

小批量训练：在实现层面上, 为规避低效的 Python 级实例遍历计算, 严格采用了向量化编程。通过充分调用 PyTorch 的底层张量乘法与广播机制, 实现了对一整个 Mini-batch 数据的并行处理, 压缩训练耗时, 兼容 GPU 加速。

反向传播：模型训练采用手动推导误差项与参数的解析梯度。

为进行反向传播, 设中间逻辑值矩阵 $Z = XW + b$ 。根据链式求导法则, 无论采用何种损失函数, 参数梯度均取决于损失 L 对逻辑值 Z 的偏导矩阵 $\frac{\partial L}{\partial Z}$:

$$\begin{aligned}\frac{\partial L}{\partial W} &= \frac{1}{B} X^T \frac{\partial L}{\partial Z} \\ \frac{\partial L}{\partial b} &= \frac{1}{B} \sum_{i=1}^B \left(\frac{\partial L}{\partial Z} \right)_{i,:}\end{aligned}$$

其中参数梯度通过批次均值 (Batch Mean) 进行缩放, 对 b 的偏导为误差矩阵按列求和。

在交叉熵损失下

$$\begin{aligned}\frac{\partial L_{\text{CE}}}{\partial Z} &= \hat{Y} - Y \\ \frac{\partial L_{\text{CE}}}{\partial W} &= \frac{1}{B} X^T (\hat{Y} - Y) \\ \frac{\partial L_{\text{CE}}}{\partial b} &= \frac{1}{B} \sum_{i=1}^B (\hat{Y}^{(i)} - Y^{(i)})\end{aligned}$$

在均方误差损失下, 令误差项矩阵 $\Delta = \frac{\partial L_{\text{MSE}}}{\partial Z} \in \mathbb{R}^{B \times C}$, 对于批次中第 i 个样本在第 j 个类别上的元素, 其计算展开为:

$$\Delta_{ij} = \hat{y}_{ij}(1 - \hat{y}_{ij})(\hat{y}_{ij} - y_{ij}) - \hat{y}_{ij} \sum_{k \neq j} \hat{y}_{ik}(\hat{y}_{ik} - y_{ik})$$


$$\begin{aligned}\frac{\partial L_{\text{MSE}}}{\partial W} &= \frac{1}{B} X^T \Delta \\ \frac{\partial L_{\text{MSE}}}{\partial b} &= \frac{1}{B} \sum_{i=1}^B \Delta^{(i)}\end{aligned}$$

在求得批次平均梯度后, 模型采用基于学习率 η 的随机梯度下降 (SGD) 算法完成参数迭代:


$$\begin{aligned}W &\leftarrow W - \eta \frac{\partial L}{\partial W} \\ b &\leftarrow b - \eta \frac{\partial L}{\partial b}\end{aligned}$$

1.3 实验设置

数据集：采用预处理后的 `new_train.tsv` 与 `new_test.tsv`。按 8:2 的比例将训练集进一步划分为训练集与验证集，用于监控过拟合。训练集样本数为 6822，验证集样本数为 1706，测试集样本数为 3309。标签类别为 5 类，训练集标签分布呈双峰分布。训练集句子长度中位数为 18，95% 分位数为 35。



(a) 训练集标签分布条形图



(b) 训练集句子长度分布直方图

图 1: 训练集数据分布

特征工程：分别采用 Bag of Words (BoW)、同时提取 Uni-gram 与 Bi-gram，以及同时提取 Uni-gram, Bi-gram 与 Tri-gram 这三种文本向量化策略。为避免数据泄露，严格按照先拟合训练集词表，再对验证集和测试集进行一致映射。过滤词频小于 3 的词。

超参数与初始化：Batch Size 设定为 20，训练 Epochs 为 100，学习率为 0.1。对 W 采用正态随机初始化， b 全零初始化。

1.4 实验与结果讨论


1.4.1 损失函数对比

研究先比较 MSELoss、CrossEntropyLoss 在分类任务上的收敛行为差异。如图 2 (a)、(b) 所示，其他条件相同时，使用 MSELoss 和 CrossEntropyLoss，训练模型的效果相近：训练损失都平滑下降，伴随验证集准确率的上升。


但是理论分析，分类任务中，Softmax 结合 MSELoss 会导致在预测值与真实标签偏差较大时，偏导数（梯度）接近于 0，使得权重更新停滞；而 CrossEntropyLoss 求导后的形式消除了激活函数的导数项，误差越大梯度越大，更适合分类问题的优化。

两种损失函数在这里效果相近，主要是因为模型简单，损失函数曲面平滑，以及恰当的初始化 (W 采用正态随机初始化， b 全零初始化)。为验证这一理论局限性，本研究刻意构造了极端偏置初始化 $b = [20, 0, 0, 0, 0]$ ，以模拟高偏差初始状态。如图 2 (c)、(d) 所示，在此条件下 MSELoss 损失的权重更新完全停滞，暴露出其在处理极端分类错误


时的优化缺陷，而 CrossEntropyLoss 损失仍能迅速修正偏差并完成收敛。基于此结论，后续实验均确立 CrossEntropyLoss 为默认损失函数。




(a) BOW + MSE



(b) BOW + CE



(c) BOW + MSE + 极端初始化



(d) BOW + CE + 极端初始化

图 2: 不同损失函数的训练效果对比

1.4.2 特征表示差异: BoW、Bi-gram、Tri-gram

由图 2 (b)，采用 CrossEntropyLoss 时训练损失已经平滑下降，训练集正确率也逼近 80%，而验证集损失与正确率在小幅优化后就陷入平台期。这说明模型过拟合，这主要归因于 Bag of Words (BoW) 模型仅将文本视为词汇的无序集合，完全丢失了词序与局部上下文语义信息，导致表征能力受限。因而研究采取特征提取能力更强的 Bi-gram (同时提取单个单词和相邻两个单词的所有组合作为特征) 和 Tri-gram (同时提取单个单词、相邻两个、相邻三个单词的所有组合作为特征)。在相同的超参数下，对比三种特征提取方法的性能：BoW 模型在测试集上达到了 47.79% 的准确率，Bi-gram 模型达到了 48.39%，Tri-gram 模型达到了 48.27%，验证了局部上下文对情感极性判断的积极作用。

表 1: 不同特征提取方法的性能对比

特征表示方法	词表大小	测试集正确率	测试集 F1-Macro
Bag of Words	4755	47.79%	40.82%
Uni-gram + Bi-gram	9852	48.39%	41.94%
Uni-gram + Bi-gram + Tri-gram	11205	48.27%	42.00%

1.4.3 学习率敏感度

学习率网格搜索：测试了 $\eta \in \{0.001, 0.01, 0.1, 0.5\}$ 。当学习率过大（如 $\eta = 0.5$ ）时，模型快速过拟合，十个 epoch 后训练集正确率迅速逼近 1，验证集 loss 不降反升（见图 4 (a)）；当学习率过小（如 $\eta = 0.001$ ）时，模型学习速度较慢（见图 4 (d)）。；当 $\eta = 0.1$ 时，模型在第 20 个 Epoch 左右，验证集 loss 较低且平稳，验证集正确率较高且平稳，被确认为当前网络架构下的最优超参数。





(a) $\eta = 0.5$ (b) $\eta = 0.1$ (c) $\eta = 0.01$ (d) $\eta = 0.001$

图 3: 不同学习率的训练效果对比

2 Task-2: 基于深度学习的文本分类

2.1 研究背景

本研究的背景和数据与 Task1 完全相同（见 1.1 节）。

2.2 模型架构

模型架构：参考 Yoon Kim (2014)，模型设计三路并行 1D 卷积核，卷积核大小设为 3, 4, 5，每种 100 个。卷积层输出经过 Dropout(0.5) 后进入全连接层分类。

架构分析：卷积核可以看作一种特征提取器。三路并行卷积核（尺寸分别为 3, 4, 5）等价于在连续词向量空间中提取 Tri-gram、4-gram 和 5-gram 的局部语义特征。Max-Pooling 可以提取各个特征图的最强信号并解决变长序列的维度对齐问题。暂退是一种正则化手段，可以避免模型过度依赖特定层参数，提升泛化能力。另外，训练中每轮计算全连接层 W 的 l_2 范数，并将其控制在 3 以下。

2.3 实验设置

数据集：数据选取与验证集比例与 1.3 节完全相同。

特征工程：由于 N-gram 产生高维稀疏矩阵，导致特征稀疏，容易产生过拟合，内存爆炸等问题，研究转向使用低维稠密向量的词嵌入。以训练集句子长度的 95% 分位数 35（见图 1 (b)）对句子截断/填充，而后建立整数映射，使用 GloVe300d 预训练词嵌入。

优化器与学习率：参考 Yoon Kim (2014)，采用 Adadelta。

超参数与初始化：Batch Size 设定为 30；训练 Epochs 为 40，配合早停：连续 5 个 epoch 验证集损失未降低就停止；学习率为 1。对模型卷积层和全连接层 W 采用 *Xavier* 初始化，对全连接层 b 全零初始化。

2.4 实验与结果讨论

2.4.1 词向量初始化策略评估 (GloVe vs. Random)

研究评估了下述三种词嵌入方法的性能差异。

随机初始化：300 维词向量从均匀分布随机抽取，选取均匀分布的边界使得分布总体方差与预训练 GloVe300d 词向量的样本方差一致。

GloVe300d-Frozen：使用预训练 300 维 GloVe 词向量，但是保持词嵌入层参数不随反向传播更新。这一设置旨在最大化运用 GloVe 特征的泛化性。本研究数据集在 GloVe300d 中命中率为 93.00%。进一步的词频溯源与特征分析表明，未命中词 (OOV)

主要表现为强口语化的连字符复合词与生造词（如‘junk-calorie’, ‘raw-nerved’, ‘mistaken-identity’, ‘wafer-thin’, ‘fun-for-fun’ 等）。从语言学特征来看，此类非标准的修辞表达往往暗含着高度浓缩且极端的主观情感极性，是细粒度情感分类任务中的核心判定特征。由于静态预训练词向量无法有效映射此类长尾复合词，导致模型在特征提取层面对关键的局部情感线索产生了不可逆的表征丢失，这亦是限制基于 GloVe 的深度模型在该短文本数据集上进一步突破性能上限的核心阻碍之一。

GloVe300d-Finetuned: 使用预训练 300 维 GloVe 词向量，随反向传播更新嵌入层参数。这一设置旨在微调得到更好的特征表示。

实验中，使用 Random 词嵌入层的模型，验证集准确率小幅提升后便陷入过拟合，测试集正确率最低。使用 GloVe 词嵌入层的模型在 3 个轮次左右迅速学习到训练集的所有特征，随后陷入过拟合。特别地，GloVe300d-Frozen 在测试集表现优于 GloVe300d-Finetuned。对比 Yoon Kim (2014) 原始论文中 Table 2 的实验结果：作者在 SST-1 数据集上的 CNN-static 准确率是 45.5%；CNN-non-static 准确率是 48.0%。模型已达到基线要求。

表 2: 不同词嵌入方法的性能对比

特征表示方法	早停轮次	测试集正确率	测试集 F1-Macro
Random	6	34.78%	31.48%
GloVe300d-Frozen	7	45.84%	41.31%
GloVe300d-Finetuned	6	39.74%	38.47%

2.4.2 优化器与学习率动态

本实验中采用 GloVe300d-Frozen 词嵌入层，对比了 Adam, SGD 与 Adadelata 的性能差异。对前两种优化器测试了 $\eta \in \{0.0001, 0.001, 0.01\}$ 。实验结果表明，不同优化器在当前短文本分类任务上的优化效率差异显著。具体而言：SGD 整体收敛缓慢，在各学习率下均未能达到最优性能；Adam 在 $\eta = 0.001$ 时展现出极快的初期收敛速度，但当学习率过大（ $\eta = 0.01$ ）时出现剧烈的损失震荡与过拟合现象。综合评估收敛平稳度与验证集最佳准确率，Adadelata 表现最为优异，基于此结论，本研究后续消融实验均默认采用该优化器配置。

2.4.3 卷积核配置的敏感度

本实验旨在评估不同卷积核配置对模型分类性能的影响。实验分为两组：一是对感受野大小的消融分析，即固定每种尺寸的卷积核数量为 100，分别测试 [2, 3, 4]、[3, 4, 5]

及 [5, 7, 9] 三组卷积核组合；二是对模型特征维度的消融分析，即固定卷积核尺寸组合为 [3, 4, 5]，测试不同输出通道数 ($c_{out} \in \{10, 30, 50, 70, 90, 100, 150\}$) 在特征提取过程中的表现差异。

感受野大小的实验数据显示，偏重短局部特征的组合 [2, 3, 4] 与经典组合 [3, 4, 5] 表现接近，测试集准确率稳定在 45% 左右，F1-Macro 约为 37.5%。然而，当感受野扩大至 [5, 7, 9] 时，模型性能出现显著衰退。该现象反映了当前短文本数据集的情感表达分布规律：情感极性高度集中在短跨度组合中。当强制使用大尺寸卷积核时，感受野跨度超过了有效语义边界，稀释了关键的情感特征。

图 (b) 展现了输出通道数与模型性能的非线性关系。首先，实验揭示了当前短文本情感极性特征的高度稀疏性。在极少通道 (10-30) 下，模型即可取得接近 45% 的最优梯队准确率；当通道数扩张至 50-90 之间时，性能呈明显下降趋势。这表明，过剩的通道并未学到增量的情感规律，反而捕获了训练集中的非情感相关噪声，导致模型在测试集上产生误判。其次，庞大参数量带来了优化灾难。观察 150 通道时的指标，尽管准确率未跌至谷底，但其最佳验证集 Loss 发生剧烈飙升。这证实了过宽的网络在当前小规模数据集上极易陷入严重的过拟合。最后，值得注意的是，图表中在 100 通道处出现的性能激增 (约 45.7%)，其与 10 通道的绝对差异不足 0.5%。考虑到数据集规模 (约 7000 条)，推测该突变主要来源于小样本下深度网络对随机初始化的方差敏感性，而非参数量本身的结构性收益。




图 4: 不同卷积核配置对模型分类性能的影响

2.4.4 跨架构模型对比

为了更好地建模长距离依赖，研究引入 BiLSTM 和 Transformer Encoder，控制总参数数量级相同，对比三者表现。

在将参数量严格控制在 10^5 同一量级后，TextCNN、BiLSTM 与 Transformer 三种架构展现出了截然不同的泛化表现。虽然三者 in Test Accuracy 上的差距相对可控

(TextCNN 45.0%, Transformer 48.8%), 但在衡量多分类均衡能力的 F1-Macro 指标上, 出现了显著的阶梯式断层: TextCNN 仅为 29.3%, BiLSTM 提升至 35.9%, 而 Transformer 实现了 42.3% 的大幅领先。这表明, TextCNN 在预测少数类时严重误判, 而 Transformer 则能较好地兼顾所有细粒度类别。这一结果可归结为三种架构底层归纳偏置的差异:

TextCNN 的局部性与池化损耗: TextCNN 依赖 Max-Pooling 提取整句的最强局部信号。这种机制擅长捕捉强烈的多数类情感词, 但彻底丢弃了词语之间的空间位置关系与长距离修饰逻辑, 导致其在面对表达委婉或逻辑转折的少数类样本时容易出现误判。

BiLSTM 的时序依赖: RNN 架构引入了严格的时序计算, 一定程度上保留了上下文逻辑, 因此在 F1 指标上优于 CNN。但其长距离记忆衰减问题依然限制了复杂语义的建模上限。

Transformer 的全局自注意力优势: Transformer 的胜出归功于其全局自注意力机制。该机制打破了 CNN 的局部窗口限制与 RNN 的时序截断, 能显式计算句子中任意两个词之间的语义关联度。这使得模型能够精准捕获跨越长距离的语义反转 (如前文铺垫与句末转折), 并在高维空间中保留完整的句法结构。




图 5: 模型架构

表 3: 不同模型架构的性能对比

模型架构	总参数量	测试集正确率	测试集 F1-Macro
TextCNN	360k	45.00%	29.34%
BiLSTM	504k	48.38%	35.92%
Transformer Encoder	513k	48.87%	42.30%

3 Task-3: 实现 Transformer 的基础结构

3.1 研究背景

在 Transformer 架构问世之前，序列建模主要依赖基于循环神经网络（RNN）或卷积神经网络（CNN）的编码器-解码器结构。然而，RNN 存在长程依赖捕捉能力弱且无法并行计算的问题，而 CNN 处理变长序列的灵活性较差。Transformer 凭借基于缩放点积注意力的自注意力机制（Self-Attention），实现了全局上下文的高效并行建模，成为现代预训练大模型（LLMs）的绝对基础架构。

尽管原始的 Encoder-Decoder 架构在机器翻译等条件生成任务中表现优异，但在处理纯自回归生成任务及大规模无监督语料预训练时，其参数利用率和结构统一性略显不足。近年来的研究表明，仅解码器（Decoder-only）架构在大规模语言数据集上展现出更强的扩展性与泛化优势。本研究旨在通过从零构建 Transformer 及其 Decoder-only 变体，对比二者在逻辑推理（多位数加法）与自然语言建模（剧本生成）两个子任务中的性能差异。

3.2 模型架构实现

本实验基于 PyTorch 框架，脱离 `torch.nn.Transformer` 的高级封装，从底层算子出发实现了标准的 Transformer 及其变体架构。核心组件构建如下：

注意力机制：严格按照原论文公式实现了缩放点积注意力，并支持多头并行计算，以捕捉不同子空间的语义特征。其计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

掩码机制：在前向传播中实现了对齐维度的 Padding Mask，以消除填充字符对注意力权重的干扰；在解码器中引入了 Subsequent Mask，确保自回归生成时严格的因果性，防止信息泄露。

层规范化与残差连接：采用了 Post-LN（Post-Layer Normalization）结构，即在注意力和前馈神经网络（FFN）之后依次进行残差加和与层归一化，有效缓解了深层网络训练中的梯度传播问题。

实验代码将上述组件封装为 `TransformerEncoderLayer` 与 `TransformerDecoderLayer`，进一步组合成完整的 Encoder-Decoder 模型。为对比架构差异，本研究额外剥离了编码器模块，构建了纯自回归的 `DecoderOnlyTransformer`。

3.3 实验一：多位数加法学习与长度泛化探究

3.3.1 数据集构建

本实验设计了多位数加法任务，加数位长在 3 至 5 位之间。随机采样生成了 8,000 条算式作为训练集，其中 20% (1,600 条) 用作验证。测试集覆盖了该长度范围内的所有组合分布（即从 3+3、3+4 直至 5+5），每种分布独立采样 200 条样本。数据格式设定为：输入序列（Prompt）格式为 `<BOS>A+B=`，目标序列（Target）为两数之和。

在数据预处理阶段，对目标结果序列进行了**逆序处理**（如 $123 + 456 = 579$ 处理为 $9 \rightarrow 7 \rightarrow 5$ ）。这一设计的核心逻辑在于：加法运算存在从低位到高位严格进位依赖。逆序输出使模型在自回归初期先预测个位，天然契合从低到高的进位计算逻辑，显著降低了模型的对齐与预测难度。

3.3.2 模型配置与超参数

表 4: 实验一模型参数配置

模型架构	Encoder 层数	Decoder 层数	注意力头数	模型维度	前馈维度	Dropout 率
Encoder-Decoder	1	1	2	64	256	0.1
Decoder-only	-	2	2	64	256	0.1

超参数设置：最大训练轮次（Epoch）设为 50，批量大小（Batch Size）为 32。优化器采用 Adam，初始学习率为 $5e-4$ 配合动态学习率衰减策略，早停（Early Stopping）耐心值设为 5。

3.3.3 泛化能力分析

为精准评估模型的泛化能力，本研究针对性地设计了内插（Interpolation）与外推（Extrapolation）泛化测试。以 (3,3) 代表三位数加三位数的子任务为例：外推测试中，训练集由 (3,3), (3,4), (4,3) 组成，测试集考察未见过的更长序列 (4,5), (5,5), (5,4)。内插测试中，训练集涵盖边界情况 (3,3), (4,5), (5,5), (5,4)，测试集考察内部未见分布 (3,4), (4,3), (4,4)。

热力图与评估指标表明：模型在同分布（IID）的已见长度组合上能达到近乎完美的精确匹配率（Exact Match, EM）。然而，在面对未见过的数位组合时，准确率发生断崖式下跌，展现出极弱的外推与内插泛化能力。

这一现象暴露了标准 Transformer 架构在算术推理上的局限性：模型本质上是在拟合特定绝对位置编码下的局部映射模式，而非习得具备高度泛化性的图灵完备算法。此外，基础的绝对位置编码在捕捉长距离的相对数值关系时存在先天不足。




图 6: 加法任务长度泛化能力评估热力图

3.3.4 架构对比与收敛分析

在严格控制参数量与超参数的条件下，对比了两种架构在加法任务上的收敛特性。结果显示，Decoder-only 在训练初期的收敛速度优于 Encoder-Decoder；但在中后期 (Epoch 增加时)，Encoder-Decoder 的收敛速度与最终准确率显著反超，达到前者的两倍以上。

准确率方面，两者在基础任务 (3,3) 上均表现优异；但在更复杂的分布中，Encoder-Decoder 表现出更强的鲁棒性。值得注意的是，两者在长序列 (4,5) 样本上均出现性能坍塌。

该表现差异可归因于模型结构的适配性：Encoder-Decoder 架构通过独立的编码器处理条件输入（加数），能够形成稳定的静态上下文表征，更契合“题目-答案”这种强映射任务。相比之下，Decoder-only 架构需要在同一套隐空间权重中兼顾“题目理解”与“答案生成”，在同等较小的参数规模下容易出现特征竞争，导致在相同的训练步数内存在欠拟合现象。




图 7: Encoder-Decoder 与 Decoder-only 架构的收敛速度对比




图 8: 不同架构在各数位组合下的准确率对比

3.4 实验二：语言模型训练

3.4.1 数据与预处理

本实验采用《老友记》(Friends) 1-10 季完整剧本作为自回归预训练语料。工程实践上对原始文本进行了场景切分、异常字符清洗，并引入了特定的舞台动作标记（如<ACTION>）以规范化语料结构。

3.4.2 Tokenizer 策略对比分析

为了探究切词粒度对模型表征的影响，本实验对比了两种分词策略：

Word-Level + GloVe 初始化：以完整单词为粒度进行切分，并利用 GloVe 100d 词向量初始化 Embedding 层。该策略在小型语料上能快速引入外部语义先验，加速初期收敛，但由于词表固定，面临严重的未登录词（OOV）困境，制约了模型的泛化生成。

Subword-Level (基于 GPT-2 BPE)：引入字节对编码（Byte Pair Encoding）分词器。该方法通过统计词频动态合并高频子串，在有效控制词表规模的同时，从根本上消除了 OOV 问题，且能更好地捕获英文单词的词缀形态，更适合长序列的连续上下文建模。

3.4.3 生成样例定性分析

在本实验中采用层数为 6 的 Decoder。通过在训练主循环中引入定期的自回归采样 (Temperature = 0.8)，本研究完整捕捉了 Decoder 模型从零开始学习人类自然语言的四个典型阶段：

- **混沌与乱码期 (Step 10 - 100):** 模型完全不具备语法概念，输出呈现无意义的字符、碎片化的子词 (Subword) 拼凑以及标点符号的随机堆砌。
- **局部格式习得期 (Step 500):** 这是一个关键的突破点。模型虽然生成的句子逻辑依然破碎，但已经精准捕获了剧本语料的核心结构特征——成功学会了“角色名：台词”的排版格式，并掌握了 <ACTION> 这一自定义舞台动作标记的闭合逻辑 (</ACTION>)。
- **基础语法构建期 (Step 1000 - 3000):** 单词拼写错误基本消失，模型开始掌握英语的基础句法结构 (如主谓宾搭配、简单的从句引导词)。例如出现了 “I thought we’s going to put the name” 等具有局部连贯性的短句。
- **语义与语感拟合期 (Step 5000):** 模型展现出了优异的上下文拟合能力。不仅能生成难句，而且其使用的词汇、停顿语气 (如 “Well”, “Oh well”) 已经高度还原了《老友记》中人物的真实口语交互语感。

这一演变过程直观且有力地证明了：在纯粹的 Next-Token Prediction (下一个词预测) 自监督目标下，Transformer Decoder 能够隐式地、自底向上地完成从“字元统计规律”到“高层句法逻辑”的逐级特征表征。详细生成日志如表 5 所示。

表 5：自回归语言模型在不同训练阶段的生成日志

```
[===== Global Step: 10 (Epoch 1) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys! Oh go left talking with Oh sureI am doing time We It It at say go it sure.
the go have P in have? at left big are be byIACH P> I Oh You twoI Well put </, Well: I theI it am.
in It left </ gonna All something sorry have talking go, it sorry put: big Ph twoI...

[===== Global Step: 100 (Epoch 1) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys! : this the you I-.,? I of <: > I,'s?>:, You? RachelACTION!: > have you:
Rachel to the.:oe> Rachel you, you> in, < :. ChandlerACTION? with </: what, </ACTION know.. : You </
you, I> I I't!oe I to, it. with a,oesACTION as I

[===== Global Step: 500 (Epoch 1) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys! </ACTION: No </ACTION>
Chandler: Oh it I know, it' the friend!
Ross:
Monica:
Pete: Well, but y't-OS>
Joey: Yeah, it, it that'm like the door?
Ross: I could not going to her and the new baby of her.
Chandler: So aeller: Yeah. You have a little? I's

[===== Global Step: 1000 (Epoch 2) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys!
```

```
Monica: Is, I do, I have a.
Phoebe: Oh-no.
Ross: Oh no, but Chandler: Look, I'm just guys'm at it is so that I need to even have.
Joey: I thought we's going to put the name.
Monica: No-what, I's not... I'm a one.
Rachel: How would have to the

[===== Global Step: 3000 (Epoch 5) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys!
Joey: Hey, hey.
Monica: Ooh.
Ross: Ooh, this would be gonna be in.
Monica: Uh-huh, there go out here in the door.
Ross: <ACTION> interrupting </ACTION> .
Rachel: Yes, I was just gonna be a great.
Ross: Wait, why don't you think I wanted to you to have to go to me.

[===== Global Step: 5000 (Epoch 8) =====]
Prompt: Ross: Hey guys!
Output: Ross: Hey guys!
Monica: Hey, what's going on?
Ross: Well, I don't know, I'm making a little big surprise, but I don't think you never felt terrible
at him.
Rachel: Oh well.
Monica: Yeah, if you think of this is about a really great relationship with, I'm-I've been in love
with someone to see to tell you what they broke up.
```

3.5 总结与反思

本次实验通过底层算子构建深入验证了 Transformer 及其变体在逻辑推理与语言建模中的性能边界。研究发现，基础的绝对位置编码难以捕捉算术任务中抽象的相对拓扑关系，是导致模型长度泛化失效（无法外推至未见位数）的底层诱因；同时，在小规模参数实验中，Encoder-Decoder 架构在强逻辑对齐任务下展现出优于 Decoder-only 的表征效率与训练稳定性。针对上述局限性，后续研究可从位置表征（如引入 RoPE 或 ALiBi）、架构优化（如 Pre-LN 与 RMSNorm 改造）及推理范式（如引入思维链 CoT 或 Scratchpad）三个维度进行迭代，将单步映射解耦为多步推理，从而突破架构在逻辑推理上的瓶颈。

3.6 全文总结

本系列实验完整覆盖了从基础线性分类器到现代大规模语言模型架构的演进链路。通过 Task-1 的数学推导夯实了神经网络的代数基础，验证了局部上下文对特征表征的增益；Task-2 通过 TextCNN、BiLSTM 与 Transformer 的多维消融实验，深入剖析了不同架构归纳偏置对语义捕捉能力的本质差异；Task-3 则基于 Transformer 的全流程构建，不仅在剧本生成中验证了自监督学习的涌现潜力，更通过加法测试客观界定了当前

主流架构在算术推理中的泛化边界。整体实验链路实现了从理论逻辑到工程实践、再到深度学术探究的闭环，为后续深入研究大规模语言模型的内在机理奠定了扎实基础。