

具身智能入门练习实验报告

冯傲邦 23307100006

摘要

本报告评估了具身智能在模仿学习与大模型任务规划中的核心表现与技术瓶颈。在模仿学习维度，研究通过 PushT 任务验证了 Diffusion Policy 受时序观测界限与预测步长的显著影响，并揭示了该架构在 Aloha 双臂协同等高维任务中因维度诅咒、视觉表征局限及多峰动作分布导致的失效风险。在任务规划维度，报告利用 Code as Policies 范式成功将大模型的空间常识蒸馏至轻量化模型 Qwen2.5-7B 中，在大幅缩减推理耗时的同时提升了执行鲁棒性。此外，针对 ALFRED 场景级任务提出的双轨制思维链与结构化 ICL 有效强化了模型的错误恢复与子目标拆解能力，也剖析了当前系统在 3D 空间投射、时序记忆死锁及视觉语义幻觉方面的深层挑战。

1 任务三、基于模仿学习的机械臂抓取

1.1 研究背景

传统行为克隆在复杂具身控制中存在显著局限：1) 均方误差目标函数难以拟合多模态动作分布；2) 自回归预测在长序列执行中易引发协变量偏移与误差累积；3) 缺乏有效的时间一致性规划。Diffusion Policy 通过引入条件去噪扩散过程对动作轨迹进行建模，结合动作分块机制，被证明能有效克服上述痛点。

本报告基于 LeRobot 框架，系统评估了以 Diffusion Policy 为代表的生成式模仿学习策略。研究通过 PushT 任务的消融实验探究了“时序观察界限 (Observation Horizon)”与“预测步长 (Prediction Horizon)”对模型早期样本效率的影响；通过长周期训练验证了收敛性能；最后，将算法架构扩展至高自由度的 Aloha 双臂协同任务中，剖析了现有基线配置在复杂系统中的局限与边界。

1.2 实验设置

环境与数据：本实验基于 gym-pusht 仿真环境，任务目标为控制单臂机器人将 T 型块推入指定目标集。使用 lerobot/pusht 官方数据集，包含 206 条专家演示轨迹。

- **状态观测空间：**包含 96×96 分辨率的全局 RGB 图像及末端执行器的二维坐标。

- **动作空间**：二维连续动作空间，表示末端执行器在平面内的目标绝对位移。

超参数配置：针对 Diffusion Policy 与 ACT 架构，统一采用 AdamW 优化器，学习率设为 $1e-4$ 。核心超参数配置与消融范围如下表所示：

表 1: 消融实验关键超参数配置

参数类别	具体配置 / 消融范围
视觉编码器 (Vision Encoder)	ResNet-18 (Pre-trained)
骨干网络 (Backbone)	Diffusion: UNet / ACT: Transformer
观测界限 (n_{obs_steps})	2 (Baseline) / 4 (Long Obs)
预测步长 ($horizon$)	16 (Baseline) / 4 (Short) / 24 (Long)
动作执行步数 (n_{action_steps})	8 (除 Exp 3 设为 4 外统一)
扩散步数 (Inference Steps)	100 (DDPM Scheduler)
训练总步数 (Total Steps)	40,000 (消融探究) / 100,000 (收敛验证)

1.3 PushT 任务样本效率与消融分析

为探究各组件对早期拟合速度的影响，在受限算力预算（40,000 steps）下进行了 5 组平行对比实验。在此极早期的观测窗口内，不同配置展现出显著的收敛差异：

时序上下文的增益：当历史观测视界从 2 帧扩展至 4 帧时，模型率先突破 0 成功率瓶颈（达到 10%）。这表明在涉及物理碰撞与推挤的闭环控制中，增加时序观测不仅未引发高维状态过拟合，反而有效帮助网络隐式建立了对物体动量与动态特征的物理表征。

预测步长 (Horizon) 的双刃剑效应：

- **短视界缺陷** ($horizon = 4$)：尽管局部拟合 Loss 最低，但严重缺乏全局视野，导致动作出现卡顿与断裂，无法形成连续规划。
- **长开环误差** ($horizon = 24$)：过长的预测步长导致开环执行期间环境发生动态变化，微小累积误差被放大，同样导致最终任务失败。

跨架构样本效率对比：在同等早期训练预算下，基于 Transformer 的 ACT 模型表现出更高的样本复杂度，未显现有效收敛。这部分归因于缺乏 CNN 或 UNet 等局部归纳偏置，在有限 steps 下难以快速建立空间视觉-运动映射。

1.4 定性与长期收敛验证

为验证策略的最终表现上限，研究对 Baseline 进行了 100,000 步的充分训练。在流形完全拟合后，Diffusion Policy 展现出高精度的闭环控制鲁棒性（见图2）。面对初始位




图 1: PushT 任务早期样本效率表现

置扰动或轻微碰撞偏离，策略能够实时生成向心纠正动作，体现了生成式模型对演示数据中“多模态修正行为”的出色泛化能力。





图 2: PushT 100k 步训练后闭环推挤定性过程

1.5 高自由度 Aloha 任务的失效探究


为评估算法架构的泛化上限，研究将同样的架构与默认超参数直接迁移至极具挑战的 Aloha 双臂协同插入任务，并执行完整的 100k 步训练。评估阶段任务成功率为 0，表现为双臂高频抖动及缺乏协调。该“局部 Loss 收敛但全局决策失效”的现象暴露了基线配置在复杂系统中的瓶颈：

1. **高维空间与 Horizon 匹配度失衡**：动作空间由单臂 2D 平面跃升至双臂 14 DoF 的 3D 空间，所需的运动规划周期被大幅拉长。默认的 $horizon = 16$ 极有可能无法覆盖一次完整的“协同-逼近-插入”微动作周期，导致策略陷于局部高频振荡。
2. **多视角视觉表征的局限**：Aloha 强依赖多机位（如左右腕部与全局视角）提供深度与空间信息。若视觉编码部分未能进行有效的空间对齐或使用过早的特征融合 (Early Fusion)，会导致严重的 3D 状态混淆。

3. **异构动作分布的极端多峰性**：协同任务涉及双臂动作的高度解耦与重耦合（如一臂固定，另一臂微调）。常规的扩散模型去噪网络容量在应对此类包含“静止-极动”骤变的多模态分布时，存在欠拟合风险。



(a) 右臂位姿失调



(b) 双臂协同失败与高频振荡

图 3: Aloha 双臂任务的典型失效案例

1.6 结论与展望

本实验完成了从单臂二维控制到双臂三维协同的具身策略部署闭环。研究验证了 Diffusion Policy 在低维空间通过扩大时序观测界限能够显著提升样本效率，同时也客观指出当前默认配置在高维协同任务上面临的严重“维度诅咒”与表征瓶颈。未来工作将重点围绕 Aloha 任务进行网络适配，探索引入自适应动作分块、扩大模型容量，以及优化多视角特征融合策略。

2 任务五、基于 LLM/VLM 大模型的任务规划

2.1 桌面级任务：基于 Code as Policies 的机械臂规划

2.1.1 研究背景

传统的端到端强化学习或模仿学习在具身智能中面临数据收集成本高、泛化能力弱的问题。CaP 提出利用 LLM 编写 Python 代码来表达机器人的策略与控制循环，从而直接继承 LLM 的空间常识与逻辑能力。为了复现并验证该范式，本文独立搭建了基于 Franka Panda 机械臂的 PyBullet 桌面仿真环境，针对两大任务：堆叠物块和移动物块设计了高度抽象的动作原语 API，打通了从自然语言指令到物理引擎驱动的完整闭环。

2.1.2 原子控制原语

为使大模型能够轻松输出控制代码，研究对底层的逆运动学求解和关节控制进行了高级封装，提供了以下主要原子函数：

- `get_object_coordinates()`: 获取当前场景中所有物体的 3D 坐标。
- `simple_pick(robot_id, obj_pos, grip_orn)`: 包含悬停、下降、抓取、校验、抬升的完整动作流。
- `move_to(robot_id, ee_index, pos, target_orn)`: 控制末端执行器移动至目标坐标。
- `stack(block1, block2) / place_in_bowl(block, bowl)`: 封装好的复合任务函数。

特别地，`grasp()` 函数采用“虚拟约束焊死”的方法代替基于摩擦力的物理抓取，极大提高了仿真的稳定性和数据收集的成功率。

2.1.3 基于现有模型的 Prompt 规划与评估

为验证 CaP 在当前大模型上的有效性，研究设计了包含上下文学习和思维链的系统提示。

- **状态感知闭环**: 提示词要求模型首先调用 `get_object_coordinates()` 解析当前环境的 3D 拓扑结构。
- **CoT 推理**: 强制模型在输出代码前，输出 "Thinking: ..." 字段，显式计算物体间的三维距离，并据此决定机械臂的抓取姿态（如通过计算 Yaw 角生成 `dynamic_orn`）。

通过对 DeepSeek-Chat 模型的零样本推理测试表明，现有高能力 LLM 能够准确理解空间方位，并严格遵循 API 约束输出结构化 Python 代码，顺利完成“Pick and Place”及“Stacking”任务。

2.1.4 基于 Qwen2.5-7B 的闭环指令微调 (SFT)

尽管 API 调用效果显著，但依赖高能力闭源模型存在推理延迟高和部署成本大的问题。为此，研究探索了将复杂规划能力蒸馏至 7B 级别模型的工程路径。

自动化数据生成：研究使用高能力的 DeepSeek-Chat 模型作为“教师模型”来自动收集微调数据，流程如下，

1. 向教师模型提供系统 Prompt 及当前环境的状态（包含物体的坐标）。
2. 教师模型输出思维链（CoT）推理和对应的 Python 控制代码。
3. 将生成的代码直接注入 PyBullet 引擎中执行（`exec()`）。
4. 执行完毕后，调用 `evaluate_task()` 函数，通过计算物体执行前后的欧氏距离等物理规则来判定任务是否成功。

只有通过物理引擎校验的成功轨迹才会被保存为 JSONL 格式的微调数据。单条数据结构如下，在 200 次数据收集中收集了 163 条成功数据。

```

1 {
2   "instruction": "Put the red_block in bowl1.",
3   "input": "Current State: {'bowl1': [0.45, 0.30, 0.00], 'red_block':
4     [0.40, 0.20, 0.10]}",
5   "output": "Thinking: The red_block is at [0.4, 0.2]. Bowl1 is at [0.45,
6     0.3]. Distance is within reach. I will use simple_pick and place_in_bowl
7     .\n```python\nplace_in_bowl('red_block', 'bowl1')\n
8   ```"
9 }
```

Listing 1: 自动化收集的 SFT 数据示例

微调策略与训练结果：实验选用了代码理解能力优异的国产开源模型 Qwen2.5-7B。在单张 RTX 4090 显卡上，基于 LLaMA-Factory 框架使用 BF16 精度进行了 LoRA 微调（Rank=8， $\alpha = 16$ ）。设置学习率为 5×10^{-5} ，Epoch 为 8。训练结果表明，模型在约 8 分钟内达到收敛状态，最终 $Loss \approx 0.2141$ 。Loss 曲线平滑下降并保持稳定，表明微调后的 7B 模型成功内化了“环境状态描述 → 空间坐标分析 → 可执行物理代码”的映射逻辑。

2.1.5 Prompt 与 SFT 的效果对比

本研究系统性地比较了 CaP 范式下两种核心实现路径的性能差异：基于上下文学习的少样本提示与监督微调。在实验设计上，研究构建了包含 6 个具有代表性的空间操控任务指令集，并通过有放回抽样的方式，为每类模型生成了 50 次独立测试回合。该抽样策略旨在覆盖高度随机化的物理初始状态，以精准记录模型代码生成的真实成功率与推理耗时，从而消除物理引擎中的偶然性误差。在对比模型方面，研究将千亿参数级的 DeepSeek-Chat 与本研究训练的 Qwen2.5-7B Finetuned 分别作为性能上限标杆与端侧微调模型，两者均采用严格的零样本提示进行测试；同时，针对开源基座模型 Qwen2.5-7B Base，设置了零样本提示与少样本提示（包含 4 个涵盖移动与堆叠任务的示例）两个对照组，以构成完整的消融实验矩阵。

评测结果显示，引入 CaP 范式后，模型在未改变任何权重参数的情况下，移动任务成功率骤升至 65.00%。这证明了 CaP 范式的核心有效性：大语言模型具备极强的上下文学习能力，能够通过少量的 Prompt 示例，瞬间“领悟”特定的具身 API 规范与物理空间几何约束，并将其转化为结构化的可执行代码。此外，微调模型在剥离了冗长提示词的情况下，不仅在各项任务的成功率上实现了对基准模型（Base Few-shot）的全面超越，其平均推理耗时更是大幅缩减至基准模型的一半左右（如移动任务耗时从 5.62s 降至 2.70s）。这有力地证实了微调技术能够有效将复杂的 CaP 规则与空间推理能力内化于模型权重中，在摆脱对少样本提示重度依赖的同时，显著提升了端侧具身智能系统的实时响应能力与执行鲁棒性。

模型配置 (Model)	堆叠任务成功率	堆叠平均耗时 (s)	移动任务成功率	移动平均耗时 (s)
DeepSeek-Chat (Zero-shot)	86.36%	2.11	100%	2.09
Qwen2.5-7B Finetuned (Zero-shot)	54.84%	2.38	68.42%	2.70
Qwen2.5-7B Base (Few-shot)	40.00%	5.38	65.00%	5.62
Qwen2.5-7B Base (Zero-shot)	34.62%	8.92	4.17%	7.64

表 2: 不同模型在零样本与少样本提示下的具身任务性能评测结果

2.1.6 结论

本实验成功复现了 Code as Policies 在桌面环境下的应用。实验证明，只要底层控制接口封装得当，并通过 ICL 注入适当的空间物理常识，大语言模型完全具备作为复杂反应式机器人控制器的潜力。下一步计划将此范式迁移至场景级任务（如 EmbodiedBench），探索 ReAct 机制在复杂环境探索中的应用。

2.2 场景级任务：大语言模型具身规划

具身智能要求智能体在复杂的 3D 环境中通过自然语言指令完成长程物理交互任务。本节基于具备高度挑战性的 ALFRED 基准测试，要求智能体将高层宏观指令（如“清洗汤勺并放在桌子上”）自主分解为低层控制动作。本文旨在评估多模态大模型在该场景下的基线表现，并针对性地提出基于上下文学习（ICL）与思维链（CoT）的改进架构。

2.2.1 系统配置与基线设定

环境与仿真器

实验环境部署于 AutoDL 远程容器系统，物理引擎采用 AI2-THOR 5.x 版本，并运行于虚拟 X11 屏幕（Xvfb）以支持无头渲染。评测框架选用 EmbodiedBench，重点切入其细分的厨房与浴室场景任务。

模型选择与基线策略

研究选用 **Qwen-3.5-Omni-Plus** 作为核心决策规划器，利用其视觉-语言多模态处理能力，通过闭环的“指令下发-视觉反馈”完成交互。在基线（Baseline）测试中，采用纯多模态输入模式（*language_only* = 0），输入提示词框架定义为：

$$P = \{S, E_{1..n}, O_t, I\} \quad (1)$$

其中 S 为系统预设指令， E 为 10-shot 随机采样示例， O_t 为仿真器渲染的当前帧视觉观察与检测框坐标， I 为当前任务指令。

2.2.2 方法论改进：结构化 ICL 与双轨制 CoT

针对基线测试中暴露的规划失效与环境适配问题，本研究在 EmbodiedBench 的导航交互任务（eb-alf）与精细操作任务（eb-man）中引入了以下联合策略：

1. 包含错误恢复的结构化 ICL

摒弃系统默认的随机采样，人工构建了 2-Shot 高质量上下文示例。核心突破在于打破了传统的“完美指令—动作”映射，在上下文中显式注入了“试错与纠偏”（Trial and Error）的轨迹反馈。例如，向模型展示“执行拾取 → 引擎报错：距离过远 → 反思：需修正位姿 → 执行前移”的完整闭环，迫使模型学习从物理引擎异常中动态修正规划。

2. 稀疏与密集双轨制思维链

为兼顾长程导航的效率与精细操作的准确性，设计了自适应思维链：

- **稀疏型 CoT (eb-alf)**：仅在目标切换、跨房间导航与异常发生时进行深度推理，以节省长程任务中的 Context Window 被无关帧撑爆。

- **密集型 CoT (eb-man)**: 针对微操任务, 要求模型对每一帧的三维空间关系进行精确测算。

在输出动作空间前, 强制模型以严格的 JSON 格式输出四维状态机推理 (包含: 目标分解、常识推理、状态追踪、异常处理), 输出范式如下所示:

```

1 {
2   "1. Goal Decomposition": "The task is to put a towel in a tub. This
   requires: (a) finding a hand towel, (b) picking it up, (c) finding a
   bathtub, (d) moving to the tub, and (e) putting the towel down into it
   .",
3   "2. Commonsense Reasoning": "Towels are typically found in bathrooms —
   near sinks, in cabinets, or hanging on racks. Bathtubs are also in
   bathrooms. Since previous attempts to find HandTowel, Potato, Cabinet,
   Sink, and Bathtub failed, I may be in the wrong room or need to explore
   further.",
4   "3. State Tracking": "Last action was 'find a Cabinet' (id 48), which
   failed — likely because no cabinet is visible here or it's not
   accessible from this position.",
5   "4. Exception Handling": "Repeated failures suggest I'm not in the correct
   location. I should try to navigate toward a bathroom by looking for
   doors or hallways leading there. Since the image shows a doorway to
   another room, I should move through it to search for bathroom items."
6 }

```

Listing 2: 双轨制 CoT JSON 输出规范示例

2.2.3 实验结果与失败归因

性能评估

我们对 50 个任务回合进行了阶段性评估。初步结果显示, 缺乏结构化引导的基线模型陷入了零成功率的困境。引入提出的 ICL+CoT 架构后, 模型在子目标完成率上展现出了初步的推理能力。

失败案例深度剖析

基于对运行日志的拆解, 基线模型 0% 成功率的核心症结可归因于以下三个维度:

1. **2D-3D 空间投射失败**: 模型依赖 2D 检测框, 无法精确建立目标深度的 3D 估算, 频繁触发 OutOfReach 异常。
2. **状态机死锁**: 智能体缺乏有效的时序记忆管理, 导致在“开门 → 视线受阻 → 关门”等局部状态中陷入死循环。

3. **视觉-语义幻觉：**受到预训练分布影响，模型倾向于猜测视野外存在的常见关联物体并尝试交互，违背了具身物理引擎的“所见即所得”原则。